

L'architettura Transformer

Encoder, decoder, embedding e generazione del testo un token alla volta

Da dove nasce il transformer

- Il transformer è un'architettura di rete neurale profonda (deep neural network: una rete organizzata in molti strati di calcolo in cascata).
- Viene presentata nel 2017 nell'articolo scientifico «Attention Is All You Need» (Vaswani e colleghi, Google).
- Il problema di partenza è la traduzione automatica: tradurre testi tra lingue diverse, ad esempio dall'inglese verso tedesco e francese.
- Oggi è la base della quasi totalità degli LLM (Large Language Model, grandi modelli linguistici) che usiamo ogni giorno.

2017


«Attention Is All You Need»



oggi: l'architettura alla base degli LLM

La struttura: encoder e decoder (applicate al caso “traduzione”)

Il transformer originale è composto da due blocchi che lavorano in coppia



L'encoder elabora l'intera frase in parallelo; il decoder la riscrive nella lingua di arrivo, token dopo token.

Schema concettuale semplificato — elaborazione originale per il corso

L'architettura è generale; l'addestramento determina le capacità.

L'architettura Transformer encoder–decoder stabilisce un **meccanismo**: l'encoder elabora una sequenza di ingresso e il decoder genera una sequenza di uscita, utilizzando le rappresentazioni dell'encoder. Non impone che le due sequenze siano la stessa frase in due lingue diverse. **Il medesimo schema può essere utilizzato per diversi compiti *testo* → *testo*.**

Gli embedding: dal testo ai numeri

- Le reti neurali calcolano solo con numeri: ogni token viene convertito in un embedding, cioè un vettore (una lista ordinata di numeri) che ne rappresenta il significato.
- Ogni dimensione del vettore cattura un aspetto diverso del significato; le dimensioni sono centinaia o migliaia.
- Token con significati simili ricevono vettori vicini tra loro nello spazio.
- **Nell'encoder gli embedding diventano contestuali: lo stesso token ottiene un vettore diverso a seconda della frase in cui compare.**

gatto →


0.82

-0.31

0.09


...

0.44



Self-attention: il cuore del transformer

La self-attention (auto-attenzione) permette a ogni token di «guardare» tutti gli altri token della frase e di pesarne la rilevanza. È così che il contesto seleziona il significato giusto di una parola ambigua.




Quanta attenzione il token «calcio» dedica agli altri: il peso alto su «latte» seleziona il significato di minerale, non di sport.

Pesi illustrativi, non misurati — elaborazione originale per il corso

La generazione: un token alla volta

Il decoder è autoregressivo: produce il token successivo, lo aggiunge a ciò che vede e ricomincia, fino al segnale di fine.

Passo	Il decoder vede	Token generato
1	rappresentazione della frase + ⟨inizio⟩	The
2	... + The	cat
3	... + The cat	sleeps
4	... + The cat sleeps	⟨fine⟩



È la stessa meccanica con cui gli LLM generano le risposte: non solo traduzione, ma qualunque testo.

Dal transformer agli LLM: due famiglie

Solo encoder

Capire il testo — la famiglia BERT

- addestrata a predire parole mascherate dentro il testo
- usi tipici: classificazione, analisi del sentiment, ricerca semantica

Solo decoder

Generare testo — GPT e gli LLM

- addestrata a predire il token successivo
- usi tipici: completamento, chat, scrittura di codice, traduzione

Attenzione ai termini: transformer $\neq$ LLM. Esistono transformer non linguistici (per esempio in visione artificiale) ed esistono LLM basati su architetture diverse.

Punti chiave

- Il transformer (2017) nasce per la traduzione automatica ed è oggi la base degli LLM.
- L'encoder legge l'intera frase e la rappresenta; il decoder genera il testo un token alla volta.
- Gli embedding trasformano i token in vettori numerici; la self-attention li rende sensibili al contesto.
- Due discendenze: solo-encoder per capire (BERT), solo-decoder per generare (GPT e gli LLM attuali).

Prossimo passo del corso: dentro l'encoder — attenzione multi-testa e strati feed-forward