

Transformer: la conversazione

Seconda parte della chat · 4 ottobre 2026

ANTONIO · DOMANDA

le due immagini allegate sono la descrizione dell'architettura transformer fatta da Sebastian Raschka nel suo libro seminale "Building a LLM from scratch"

Le due immagini allegate alla domanda iniziale




Figure 1.4 A simplified depiction of the original transformer architecture, which is a deep learning model for language translation. The transformer consists of two parts: (a) an encoder that processes the input text and produces an embedding representation (a numerical representation that captures many different factors in different dimensions) of the text that the (b) decoder can use to generate the translated text one word at a time. This figure shows the final stage of the translation process where the decoder has

to generate only the final word ("Beispiel"), given the original input text ("This is an example") and a partially translated sentence ("Das ist ein"), to complete the translation.

01 La figura encoder-decoder

CHATGPT · RISPOSTA

Le immagini descrivono il **Transformer originale nella configurazione encoder-decoder**, presentato nel 2017 e applicato alla traduzione automatica. È importante mantenere la precisazione «*originale*»: non tutti i modelli basati su Transformer hanno entrambi questi componenti. (arxiv.org)

Come leggere lo schema

L'encoder elabora il testo di partenza completo, nell'esempio «This is an example», e produce una sequenza di rappresentazioni numeriche contestualizzate: ciascuna rappresentazione tiene conto anche degli altri elementi della frase. Queste rappresentazioni vengono messe a disposizione del decoder. (arxiv.org)

Il decoder genera progressivamente la traduzione, utilizzando sia le rappresentazioni prodotte dall'encoder sia il testo già generato. Nel momento illustrato, dispone della traduzione parziale «Das ist ein» e deve aggiungere «Beispiel». La figura parla di una parola alla volta per semplicità; tecnicamente la generazione procede per **token**, che non coincidono necessariamente con parole intere. (arxiv.org)

Il collegamento con la discussione precedente

Questa figura descrive un'architettura e il suo funzionamento durante la generazione, non identifica da sola il tipo di apprendimento. Il Transformer originale per la traduzione veniva addestrato su coppie di frasi nelle due lingue: testo di partenza e traduzione di riferimento. Si trattava quindi di un compito supervisionato, anche se il decoder imparava a prevedere il token successivo. (arxiv.org)

Il punto da conservare per la spiegazione in aula è dunque:

Prevedere il token successivo non significa automaticamente fare apprendimento auto-supervisionato: bisogna considerare come sono stati costruiti il compito e le risposte attese.

Infine, nei modelli **GPT di tipo decoder-only** non c'è un encoder separato come quello sulla sinistra della figura: Raschka stesso evidenzia questa differenza nel suo materiale didattico. (sebastianraschka.com)

02 Come il decoder genera la traduzione

ANTONIO · DOMANDA

in questo esempio è il decoder che fa la traduzione? in che modo?

CHATGPT · RISPOSTA

Sì: il decoder è la parte che genera il testo tradotto. Ma non lavora da solo: utilizza le informazioni sulla frase originale preparate dall'encoder. La traduzione è quindi il risultato della collaborazione fra i due componenti. (arxiv.org)

1. L'encoder prepara la frase da tradurre

Nell'esempio, l'encoder riceve:

This is an example

La trasforma in una **sequenza di vettori contestualizzati**: rappresentazioni numeriche dei token che tengono conto anche degli altri token della frase. **Non produce già la traduzione tedesca**; produce le informazioni che il decoder utilizzerà per generarla. (tensorflow.org)

2. Il decoder combina due fonti di informazione

Nel momento rappresentato dalla figura, il decoder deve continuare:

Das ist ein ...

Per farlo, utilizza sia **la frase inglese codificata dall'encoder**, sia **la traduzione tedesca già generata**. Queste due fonti vengono elaborate attraverso due meccanismi distinti. (arxiv.org)

La self-attention considera il testo tedesco già prodotto. Permette di mettere in relazione i token di «Das ist ein», senza accedere ai token futuri.

La cross-attention consulta le rappresentazioni della frase inglese. Permette al decoder di combinare le informazioni provenienti dalle diverse posizioni del testo sorgente, attribuendo loro pesi diversi per la previsione corrente. È il collegamento fondamentale fra encoder e decoder. (arxiv.org)

Gli strati di uscita trasformano il risultato in probabilità sui possibili token successivi. La procedura di decodifica usa queste probabilità per scegliere come continuare. Nel percorso illustrato, la continuazione è «Beispiel». Il calcolo può essere riassunto così: (nlp.seas.harvard.edu)

$$P(\text{prossimo token} \mid \text{frase inglese, tedesco già generato})$$

Quindi **non sta cercando soltanto una continuazione plausibile di «Das ist ein»**: sta cercando una continuazione coerente anche con il testo inglese da tradurre.

3. Ma chi ha scritto «Das ist ein»?

Lo ha generato il decoder nei passaggi precedenti. Nella traduzione da zero, non occorre che l'utente fornisca una traduzione parziale: si parte da un segnale di inizio e si riutilizza progressivamente ciò che è stato generato. Il processo termina quando viene prodotto un segnale di fine. Tecnicamente si procede per token; nella tabella semplifico usando parole intere. (tensorflow.org)

La rappresentazione della frase inglese «This is an example» rimane disponibile durante tutti i passaggi:

Testo già disponibile al decoder	Prossimo elemento generato nell'esempio
Segnale di inizio	Das
Das	ist
Das ist	ein
Das ist ein	Beispiel
Das ist ein Beispiel	Segnale di fine

La figura mostra dunque soltanto il penultimo passaggio della tabella, non l'intero processo.

4. Come ha imparato a farlo?

Durante l'addestramento vengono fornite molte coppie **frase originale → traduzione di riferimento**. Il modello riceve la frase sorgente e il prefisso corretto della traduzione, e viene addestrato a prevedere il token seguente. L'errore rispetto alla traduzione di riferimento serve ad aggiornare i pesi **sia dell'encoder sia del decoder**. Non è quindi il semplice nome "decoder" a conferirgli la capacità di tradurre: è l'addestramento sul compito. (nlp.seas.harvard.edu)

Il punto chiave: il decoder genera la traduzione un token alla volta, condizionando ogni previsione sia sull'originale sia su quanto ha già tradotto. (arxiv.org)

03 Architettura generale, modello specializzato

ANTONIO · DOMANDA

ok, questo però non è un trasformatore generico, è specializzato sulla traduzione

CHATGPT · RISPOSTA

Sì: l'esempio è specifico per la traduzione. La distinzione importante, però, è questa: **un modello può essere specializzato nella traduzione senza che la sua architettura sia riservata alla traduzione**. Il Transformer originale fu sperimentato soprattutto sulla traduzione, ma già il primo articolo ne mostrava l'applicazione anche all'analisi sintattica. (arxiv.org)

L'architettura è generale; l'addestramento determina le capacità

L'architettura Transformer encoder-decoder stabilisce un meccanismo: l'encoder elabora una sequenza di ingresso e il decoder genera una sequenza di uscita, utilizzando le rappresentazioni dell'encoder. **Non impone che le due sequenze siano la stessa frase in due lingue diverse**. Il medesimo schema può essere utilizzato per diversi compiti *testo → testo*. (research.google)

Nel caso della traduzione inglese-tedesco, l'addestramento su coppie di frasi nelle due lingue ottimizza i pesi di entrambi i componenti per quel compito. Il decoder produce quindi testo tedesco coerente con l'originale inglese **perché il modello è stato addestrato a farlo**, non perché "decoder" significhi "traduttore". (arxiv.org)

Con un addestramento appropriato, lo stesso schema architetturale può essere impiegato così: (research.google)

Compito	Ingresso all'encoder	Testo generato dal decoder
Traduzione	Frase in inglese	Traduzione in tedesco
Riassunto	Documento lungo	Riassunto del documento
Risposta a domande	Testo di riferimento e domanda	Risposta alla domanda
Classificazione	Recensione	Etichetta, per esempio «positiva»

Questo **non significa che un modello addestrato soltanto a tradurre sappia automaticamente svolgere tutti gli altri compiti**. Significa che non occorre cambiare necessariamente architettura: occorrono dati e addestramento adeguati. **T5**, per esempio, utilizza un Transformer encoder-decoder preaddestrato e adattabile a diversi compiti testuali. (jmlr.org)

Quindi la lettura più precisa della figura è:

«Architettura Transformer encoder-decoder illustrata attraverso un'applicazione alla traduzione».

Non: «Architettura utilizzabile soltanto per tradurre»; e nemmeno: «Modello necessariamente generalista perché è un Transformer».

04 Compiti e applicazioni dei Transformer

ANTONIO · DOMANDA

a quali compiti si può applicare l'architettura transformer?

CHATGPT · RISPOSTA

L'architettura **Transformer** si può applicare a **compiti di classificazione, estrazione di informazioni, previsione e generazione**, e non soltanto al linguaggio: esistono Transformer per immagini, audio, video e dati numerici. **Non è quindi sinonimo di “traduttore”, né di “LLM”, né di “modello generativo”**. BERT e Vision Transformer, per esempio, mostrano applicazioni all'analisi del testo e alla classificazione di immagini. ([arxiv.org](#))

È utile parlare di **famiglia di architetture Transformer**: la configurazione encoder-decoder del disegno è una delle possibilità, non l'unica.

1. A quali compiti si applica concretamente?

Gli esempi nella tabella illustrano possibili applicazioni: **non implicano che un singolo modello sappia svolgerle tutte**.

Ambito	Compiti	Esempio di ingresso → uscita
Analisi del testo	Classificazione, riconoscimento di entità, risposta a domande su un testo. Modelli come BERT possono essere adattati a questi compiti.	Recensione → «positiva»; documento → nomi di persone e organizzazioni. (arxiv.org)
Trasformazione e generazione di testo	Traduzione, riassunto, completamento e produzione di testo. Esempi: T5 e modelli GPT .	Documento lungo → riassunto; frase inglese → traduzione italiana. (jmlr.org)
Ricerca semantica	Produzione di embedding per confrontare frasi e recuperare contenuti semanticamente simili. Esempio: Sentence-BERT .	Domanda → rappresentazione numerica da confrontare con quelle dei documenti. (arxiv.org)
Codice software	Generazione e completamento di codice a partire da descrizioni o codice parziale. Il lavoro originale su Codex studia proprio questo impiego.	Descrizione di una funzione → codice Python. (arxiv.org)
Analisi delle immagini	Classificazione, individuazione di oggetti e segmentazione, cioè identificazione delle regioni dell'immagine. Esempi: ViT e DETR .	Fotografia → categoria; scena → oggetti con le rispettive posizioni. (arxiv.org)

Ambito	Compiti	Esempio di ingresso → uscita
Generazione di immagini	Generazione mediante modelli di diffusione che utilizzano blocchi Transformer. Esempio: Diffusion Transformer – DiT .	Rumore e indicazione della categoria desiderata → immagine generata. (arxiv.org)
Audio e parlato	Riconoscimento del parlato e trascrizione. Esempio: Whisper .	Registrazione vocale → testo trascritto. (arxiv.org)
Video	Classificazione di video e riconoscimento delle attività rappresentate. Esempio: ViViT .	Sequenza di fotogrammi → categoria dell'azione. (arxiv.org)
Dati multimodali	Combinazione di immagini e linguaggio per descrivere contenuti visivi o rispondere a domande su di essi. Esempio: BLIP-2 .	Immagine + domanda → risposta testuale. (proceedings.mlr.press)
Serie temporali	Previsione di valori futuri a partire da osservazioni passate. Esempio: PatchTST .	Serie storica dei consumi → consumi previsti nei periodi successivi. (arxiv.org)
Dati tabellari	Classificazione e regressione su variabili numeriche e categoriche. Esempio: FT-Transformer .	Caratteristiche di un immobile → prezzo stimato. (arxiv.org)
Raccomandazioni	Modellazione delle preferenze a partire dalla sequenza di interazioni di un utente. Esempio: BERT4Rec .	Cronologia delle interazioni → elementi da raccomandare. (arxiv.org)
Robotica	Produzione di azioni a partire da osservazioni visive e istruzioni linguistiche. Esempio: RT-2 .	Immagine della scena + istruzione → azioni del robot. (arxiv.org)

2. Perché funziona anche quando i dati non sono parole?

Il Transformer elabora rappresentazioni numeriche, non parole in quanto tali. Il principio dell'attenzione permette di combinare le informazioni provenienti dai diversi elementi dell'ingresso. Nel Transformer linguistico questi elementi corrispondono a token testuali; in altri modelli possono rappresentare porzioni di immagini o segmenti di una serie temporale. ([arxiv.org](#))

Per esempio, **Vision Transformer divide un'immagine in piccole porzioni, chiamate patch**, le trasforma in vettori e le elabora come una sequenza. **PatchTST compie un'operazione analoga su finestre di osservazioni temporali**. Non occorre trasformare l'immagine o i numeri in una frase: occorre costruire una rappresentazione numerica adatta al modello. ([arxiv.org](#))

3. Si usano sempre encoder e decoder?

No. Nei modelli linguistici è utile distinguere tre configurazioni principali:

Configurazione	Funzionamento essenziale	Impieghi frequenti
Encoder-only	Elabora l'ingresso e produce rappresentazioni utilizzabili da uno strato di uscita specifico.	Classificazione, estrazione di informazioni, rappresentazioni del testo. Esempio: BERT . (arxiv.org)
Decoder-only	Nei modelli autoregressivi, genera il token successivo usando il contesto precedente.	Completamento e generazione di testo o codice. Esempi: GPT , Codex . (arxiv.org)
Encoder-decoder	L'encoder rappresenta l'ingresso; il decoder genera un'uscita condizionata su quelle rappresentazioni.	Traduzione, riassunto e altri compiti sequenza → sequenza. Esempi: Transformer originale , T5 . (arxiv.org)

Queste associazioni **non sono vincoli esclusivi**: per esempio, T5 può effettuare una classificazione generando come testo l'etichetta della classe. La scelta dipende da come viene formulato il compito e da come viene addestrato il modello. ([jmlr.org](#))

Una conseguenza importante: non tutti i Transformer generano un token alla volta

Quel meccanismo riguarda i **Transformer autoregressivi**, come il decoder usato nell'esempio della traduzione. Non è una proprietà obbligatoria di tutta la famiglia: **DETR produce in parallelo un insieme di previsioni sugli oggetti**, mentre **DiT viene usato nel processo di diffusione per generare immagini**, non per scrivere una frase parola dopo parola. ([arxiv.org](#))

4. Che cosa determina il compito effettivo?

Non basta scegliere "un Transformer". Occorre stabilire **come rappresentare gli ingressi, quale configurazione utilizzare, quale uscita produrre e su quali dati e obiettivi addestrarlo**. BERT, T5, ViT e DiT condividono elementi architetturali, ma li organizzano e li addestrano per impieghi differenti. ([arxiv.org](#))

Quindi: il Transformer è una famiglia di architetture riutilizzabile in molti problemi; il modello addestrato è una sua realizzazione concreta, con capacità specifiche. La generalità dell'architettura non rende automaticamente generalista ogni modello che la utilizza.

05 L'origine del termine «Transformer»

ANTONIO · DOMANDA

da dove deriva il termine "trasformatore"?

CHATGPT · RISPOSTA

«Trasformatore» è la traduzione di *Transformer*, il nome dato dagli autori all'architettura presentata nel 2017 nel paper *Attention Is All You Need*. Il nome richiama l'idea di trasformare l'informazione, ma ha anche un'origine più giocosa. (arxiv.org)

Perché proprio questo nome?

Secondo il racconto di Jakob Uszkoreit, uno degli autori, raccolto da WIRED, il gruppo lo scelse fin dall'inizio pensando a un meccanismo capace di **trasformare le informazioni ricevute**. C'era anche un richiamo ai **robot Transformers**, con cui Uszkoreit aveva giocato da bambino: un primo documento di progetto conteneva persino un'illustrazione di quei personaggi. (wired.com)

Quel documento si intitolava «*Transformers: Iterative Self-Attention and Processing for Various Tasks*»: quindi già il nome preliminare parlava di **elaborazione per compiti diversi**, non soltanto di traduzione. (wired.com)

Che cosa "trasforma", concretamente?

Trasforma le rappresentazioni numeriche dei dati. Per esempio, nell'encoder, la rappresentazione iniziale di un token viene aggiornata combinandola con informazioni sugli altri token, attraverso l'attenzione. Ripetendo questa operazione nei diversi strati, si ottengono rappresentazioni contestualizzate, utilizzabili per il compito finale. (research.google)

Perciò **non si chiama Transformer semplicemente perché "trasforma una frase inglese in una frase tedesca"**. Quella è un'applicazione. La caratteristica tecnica distintiva del Transformer originale è l'impiego dell'attenzione al posto dei meccanismi ricorrenti e convoluzionali usati dalle architetture precedenti per elaborare le sequenze. (arxiv.org)

In altre parole: **il nome evoca la trasformazione dell'informazione; non identifica uno specifico compito, come la traduzione.**