


Word embedding

```

-0.038194 -0.24487 0.72812 -0.39961
0.083172 0.043953 -0.39141 0.3344
-0.57545 0.087459 0.28787 -0.06731
0.30906 -0.26384 -0.13231 -0.20757
0.33395 -0.33848 -0.31743 -0.48336 0.1464
-0.37304 0.34577 0.052041 0.44946
-0.46971 0.02628 -0.54155 -0.15518
-0.14107 -0.039722 0.28277 0.14393
0.23464 -0.31021 0.086173 0.20397 0.52624
0.17164 -0.082378 -0.71787 -0.41531
0.20335 -0.12763 0.41367 0.55187 0.57908
-0.33477 -0.36559 -0.54857 -0.062892
0.26584 0.30205 0.99775 -0.80481 -3.0243
0.01254 -0.36942 2.2167 0.72201 -0.24978
0.92136 0.034514 0.46745 1.1079 -0.19358
-0.074575 0.23353 -0.052062 -0.22044
0.057162 -0.15806 -0.30798 -0.41625
0.37972 0.15006 -0.53212 -0.2055 -1.2526
0.071624 0.70565 0.49744 -0.42063 0.26148
-1.538 -0.30223 -0.073438 -0.28312
0.37104 -0.25217 0.016215 -0.017099
-0.38984 0.87424 -0.72569 -0.51058
-0.52028 -0.1459 0.8278 0.27062

```

a fixed-length numeric (real-valued) vector that represents a word



L'idea di base: le parole che sono simili tra loro tendono ad essere usate insieme più spesso: *cat and kitten more often than cat and dog, which in turn more often than house.*

Gli spazi sopra mostrati sono il **risultato** dell'embedding, lo strumento (principale) è la matrice di co-occorrenza (vedi prossima slide).

Corpus:

- ✓ It is a **nice** day out.
- ✗ Is it **nice** out?
- ✓ **Nice** day!

	it	is	a	nice	day	out
it						
is						
a						
nice						
day						
out						

The CO-OCCURENCE MATRIX: how often each couple of words occurs together in the corpus?

L'idea di base: le parole che sono simili tra loro tendono ad essere usate insieme più spesso

Corpus:

- It is a nice day out.
- Is it nice out?
- Nice day!

	it	is	a	nice	day	out
it	0					
is	2	0				
a	1	1	0			
nice	2	2	1	0		
day	1	1	1	2	0	
out	2	2	1	2	1	0

Vectors for each word start out random

They're updated so that vectors for words that occur together more often are closer to each other


	it	is	a	nice	day	out
it	0					
is	2	0				
a	1	1	0			
nice	2	2	1	0		
day	1	1	1	2	0	
out	2	2	1	2	1	0

Other popular implementations:

- **FastText**
- **Word2vec**

so we start with randomly initialized vectors they're just random strings of numbers and then we can take two pairs of vectors look at how close together they are in space look at how often they're used together and if they're very far apart in space but are used together a lot we'll move them closer together but if they're very close in space and they almost never get used together it will move them further apart and after many rounds of this you will end up with a vector space representation that approximates the information from the co-occurrence matrix this particular implementation is called glove you might have heard of this it stands for global vectors

- Embeddings are used as the input to machine learning models either for training or inference
- Visualizing patterns of usage in the training corpus after PCA



https://www.google.com/search?q=word+embedding&client=ms-android-samsung-ga-rev1&hl=it&biw=412&bih=708&tbm=vid&sxsrf=AJOqlzUKMVQKz889LaUQpYU4gCw3-WRY1A%3A1676735003405&ei=G_LwY9msGlr-kwXw3ZnICQ&oq=word+embedding&gs_lcp=ChBtb2JpbGUtZ3dzLXZpZGVvEAMyBAGAEEMyBQgAEIAEMgUIABCABDIFCAAQgAQyBQgAEIAEMgkIABAHEB4Q8QQyCQgAEAcQHhDxBDIJCAAQBxAeEPEEUABYAGCDC2gAcAB4AIABjgGIAY4BkgEDMC4xmAEAggEQbW9iaWxlLWd3cy12aWRlb8ABAQ&sclient=mobile-gws-video#fpstate=ive&vld=cid:0ca356c6,vid:oUpuABKoElw

29.11.23

La tecnica di embedding chiamata Word2Vec ha lanciato una vera e propria rivoluzione nel campo del machine learning.

Si può dire che l'intera industria oggi si basa su questa tecnica e sugli sviluppi fatti in seguito ad essa.

Comprendere gli embedding è semplice: **parole relazionate tra loro dovrebbero apparire vicine nello spazio vettoriale, mentre parole non relazionate tra loro dovrebbero apparire lontane.**

Nell'immagine allegata, vediamo come le parole "principe" e "principessa" siano vicine tra di loro, proprio come come "re" e "regina".

Ponendo che la variabile genere possa assumere solo due valori, M e F (usiamo 0 e 1), e che la variabile età possa assumere solo tre valori [Giovane, Mezz'età, Anziano] (usiamo 0, 1, 2), vediamo come degli embedding possano rappresentare queste relazioni in maniera accurata in uno spazio bidimensionale.

Questa rappresentazione riesce a catturare lo status nobiliare di un individuo andando a usare le dimensioni di genere e l'età.

Muovendoci sull'asse delle X possiamo osservare come i due nobili siano equidistanti da una dimensione che rappresenta la differenza di genere (0: maschio, 1: femmina).

Muovendoci sull'asse delle Y invece, possiamo osservare come l'età sia rappresentato dalla distanza dell'embedding dall'asse Y.

In questo modo, gli embedding delle parole possono essere utilizzati come input per i modelli di machine learning, permettendo di rappresentare in modo più preciso concetti complessi in un formato numerico.

Più dati → Vettori di qualità sempre maggiore → Modelli che useranno tali vettori per un addestramento migliore.

In questo esempio abbiamo solo due dimensioni. Di fatto, vengono addestrate delle reti neurali con lo specifico compito di trovare queste rappresentazioni su parecchie dimensioni.

Per mettere in prospettiva, modelli come GPT-3 usano più di 12.000 dimensioni.

Gli embedding possono essere utilizzati non solo per parole, ma anche per rappresentare immagini, suoni e altro.

Gli embedding sono la pietra miliare del machine learning odierno.

